

학사학위 청구논문

OFDM 신호검출을 위한 기계학습의 활용

(Application of Machine Learning for
OFDM signal detection)

2020 년 월 일

숭실대학교 IT대학
전자정보공학부 IT융합학과
이 동 재

학사학위 청구논문

OFDM 신호검출을 위한 기계학습의 활용

(Application of Machine Learning for
OFDM signal detection)

지도교수 : 이 종 호

이 논문을 학사학위 논문으로 제출함

2020 년 월 일

숭실대학교 IT대학
전자정보공학부 IT융합학과
이 동 재

이동재의 학사학위 논문을 인준함

심사위원장 _____ (인)

심 사 위 원 _____ (인)

2020 년 월 일

숭실대학교 IT대학

감사의 글

돌아보면 짧았던 학부과정의 마무리로 학사학위 논문을 무사히 작성하게 되었습니다. 매 학기 열심히 수강하였던 그 어느 과목보다도 학사학위 논문을 준비하며 진행했던 세미나, 실험, 분석들을 통해 더 많은 것을 배운 것 같습니다. 무사히 학사학위 논문을 작성하는 과정에 있어 도움을 주신 많은 분들에게 감사의 말씀을 드리하고자 합니다.

숭실대학교에서 졸업 논문 지도를 맡는 것이 처음이셨던 이종호 지도 교수님께 먼저 감사드립니다. 바쁘신 와중에도 지도학생들의 진행 상황에 항상 관심 가져주시고 논문이 완성될 수 있도록 끝까지 세심한 지도를 해주셔서 문제점이 발생할 때마다 보다 빨리 파악하고 수정할 수 있었습니다.

함께 1년 동안 고생한 동기 박경빈, 이정행에게도 감사의 글을 전합니다. 서로 공부가 부족한 부분은 세미나를 통해 보완하며 문제점을 발견한 실험 내용에 대하여 지속적으로 고민했던 지난 1년의 과정이 절대 혼자서는 해낼 수 없었음을 되돌아보며 다시금 느낍니다.

끝으로 학부과정을 무사히 마칠 수 있도록 항상 뒤에서 묵묵히 응원해주시는 부모님께 감사하다는 말을 전하고 싶습니다. 제가 미처 생각하지 못한 부분까지 항상 신경 써주시고 지켜봐주시는 부모님이 곁에 있었기에 오늘보다 내일 더 성장하는 제 자신이 될 수 있었습니다. 논문이 완성되기까지 도움을 주셨던 모든 분들에게 다시 감사의 말씀을 드리며 감사의 글을 마칩니다.

목 차

표 및 그림 목차	i
국문초록	ii
I. 서론	1
II. OFDM 및 인공신경망 기초 이론	2
II-1. OFDM 동작 이론	2
II-2. 인공신경망 기초 이론	6
III. 인공신경망을 이용한 CP 대체 OFDM 시스템 설계	8
III-1. 시스템 설계 구상	8
III-2. 학습 데이터 생성	9
III-3. 선형회귀 모델 생성 및 최적화	11
III-4. 인공신경망 적용 시스템	13
IV. 성능평가 및 분석	14
IV-1. 실험 환경	14
IV-2. 시스템의 수신 성상도	15
IV-3. 시스템의 BER 곡선	16
V. 결론	18
참고문헌	19

표 및 그림 목차

Table 1 Output of Single and Multi-Layer NN	6
Table 2 모델 생성 기본 파라미터	11
Table 3 (a) 은닉층 수에 따른 손실	12
Table 3 (b) 유닛 수에 따른 손실	12
Table 4 송·수신부 구현 파라미터 비교	14
Table 5 전송 환경 파라미터	14
Table 6 신호 대비 잡음 비율별 세 모델의 각 심볼 오류율.....	16
Fig.1 다중 반송파의 주파수 스펙트럼.....	3
Fig.2 (a) ISI 발생 전송	4
Fig.2 (b) CP를 활용한 전송	4
Fig.3 기존 OFDM 전송 블록 흐름도	5
Fig.4 심층 신경망 (Deep Neural Network)	6
Fig.5 손실함수의 계산 (Mean Square Error)	7
Fig.6 시스템 설계 구상도	8
Fig.7 (a) 입력 데이터 생성	9
Fig.7 (b) 출력 데이터 생성	9
Fig.7 (c) 적용 신경망 블록도	10
Fig.8 (a) 은닉층 수에 따른 손실 변화 추이	11
Fig.8 (b) 유닛 수에 따른 손실 변화 추이	12
Fig.9 Epoch에 따른 최종 모델 손실	12
Fig.10 인공신경망 적용 수신부 블록도	13
Fig.11 (a) 4채널 환경 성능도 비교	15
Fig.11 (b) 8채널 환경 성능도 비교	15
Fig.12 신호 대비 잡음 비율에 따른 두 모델의 심볼 오류율 비교.....	17

국문초록

OFDM 신호검출을 위한 기계학습의 활용

전자정보공학부 IT융합학과 이 동 재
지도교수 이 종 호

Abstract

유·무선 통신에서 직교 주파수 분할 다중 (OFDM) 시스템은 매우 광범위하고 다양한 분야에 쓰이고 있다. OFDM의 CP (Cyclic Prefix)를 사용하는 특성은 송·수신시에 생기는 ISI (Inter-Symbol Interference)에 의한 직교성의 파괴를 효과적으로 극복할 수 있게 한다. 본 논문은 인공 신경망과 머신러닝의 활용을 통해 CP를 사용하지 않는 시스템을 설계한다. 신경망 모델을 적용한 시스템과 기존 OFDM 시스템의 성능을 비교한 결과를 확인하고 전송률의 저하 없이도 ISI를 극복할 수 있는 새로운 방법을 제안한다.

I. 서 론

다양한 스마트 기기와 급격히 늘어난 인터넷 접속사의 수로 인해 이동통신 분야에서는 점점 더 높은 전송률을 갖는 기술을 필요로 하게 되었다. 이에 따라 직교 주파수 분할 다중 (Orthogonal Frequency Division Multiplexing: OFDM) 시스템이 개발되었다. OFDM 시스템은 서로 직교성을 갖는 부반송파 각각에 다른 데이터들을 담아 병렬 전송함으로써 높은 전송률을 얻어낼 수 있고, 주파수 선택적 페이딩을 효과적으로 극복 가능하다는 장점이 있다. 이러한 이유로 OFDM 전송 시스템은 DAB, DVB, IEEE 802.11a, 802.16의 BWA (Broad Wireless Access) 등 다양한 무선 통신 시스템에서 변조 기술로 널리 사용되고 있다^[1-4].

OFDM의 또 다른 장점은 도심지나 장애물이 많은 환경에서 신호 전송 시에 ISI (Inter Symbol Interference)가 발생하여 부반송파들의 직교성이 깨지는 문제가 발생하더라도 CP (Cyclic Prefix)를 이용하여 극복할 수 있다는 것이다^[5]. 하지만 원본 데이터의 25% 정도(802.11.a 표준)를 앞에 복사해 붙이는 CP의 영향으로 심볼의 길이, 즉 송·수신시에 symbol time이 늘어나 그만큼 전송효율이 낮아지게 된다. 이러한 손실은 데이터의 전송량이 커질수록 늘어난다.

본 논문에서는 ISI가 발생하는 환경에서 CP를 사용하지 않고 부반송파들의 직교성을 유지할 수 있는 방법으로 인공신경망 (Artificial Neural Network, ANN)을 제시한다. 채널 및 주파수 오프셋 추정 등 다양한 통신 분야에 응용되고 있는 기계학습 (Machine Learning) 기법^[6-7]을 이용하여 CP를 대체할 수 있다면 symbol time을 늘리지 않고도 원활한 송·수신이 가능할 것이다. 신호 예측을 위한 선형회귀 신경망 모델을 생성하여 다중경로의 길이와 신호 대 잡음비 등이 달라지는 다양한 채널 상황에서의 성능을 평가하였다.

본 논문의 구성은 다음과 같다. 서론에 이은 2장에서는 OFDM통신 방식과 인공신경망 기초 이론을 설명하고 3장에서는 인공신경망의 학습 과정 및 인공신경망이 적용된 OFDM 시스템을 제시한다. 4장에서는 새로운 시스템이 다양한 환경에 대한 성능을 평가 및 분석하고 5장에서 결론을 맺도록 한다.

II. OFDM 및 인공신경망 기초이론

II-1. OFDM 동작 이론

OFDM 방식은 다수의 부반송파를 통하여 데이터를 전송하는 주파수 분할 방식의 일종으로 기존 방식과 달리 신호의 직교성을 이용하여 효율적인 대역폭 사용이 가능하다. Δf 의 간격을 가진 N_s 개의 부반송파를 통해 전송이 이루어질 때 k 번째 부반송파를 통해 전송되는 정보를 M_k 라고하면 해당 조건 아래 생성되는 신호 $s(t)$ 는 송신단에서는 IDFT, 수신단에서는 DFT를 수행한 결과와 같아 IFFT 와 FFT를 사용하여 고속으로 구현할 수 있기 때문에 다음과 같이 나타낼 수 있다^[8].

$$s(t) = \frac{1}{\sqrt{N_s}} \sum_{k=0}^{N_s-1} M_k e^{j2\pi(k\Delta f)t} \quad (1)$$

동일한 조건 아래 통과대역 f_c 에서 생성되는 OFDM 신호의 등가 연속시간 신호 $\tilde{s}(t)$ 는 식(2)와 같이 표현할 수 있다.

$$\tilde{s}(t) = \frac{1}{\sqrt{N_s}} \sum_{k=0}^{N_s-1} M_k e^{j2\pi(f_c+k\Delta f)t} \quad (2)$$

이때 $\tilde{s}(t)$ 의 신호는 각 부반송파의 사인파와 식(3)과 같은 직교 조건을 만족하여 부반송파들 사이에 가드 밴드를 이용하지 않고도 단순 Gain 보상으로 손쉽게 M_k 의 복조가 가능하다.

$$\langle \cos(2\pi f_k t), \tilde{s}(t) \rangle = \int_0^T \cos(2\pi f_k t) \tilde{s}(t) dt = \frac{T}{2} \cdot M_k \quad (3)$$

여기서, T 는 시간영역에서 유효심볼의 길이로 $\frac{1}{\Delta f}$ 이다. Fig.1 은 OFDM에서 이와 같은 효율적인 대역폭 사용을 가시적으로 표현한 그림이다.




Fig.1 다중 반송파의 주파수 스펙트럼


식(2)의 OFDM 신호가 m 개의 다중경로가 존재하는 무선채널 환경에서 전송되었을 때 수신단에서의 통과대역 신호 $r(t)$ 는 식(4)와 같다.

$$r(t) = \sum_{i=1}^m h_i \cdot \tilde{s}(t - \tau_i) \quad (4)$$


$$r_n = r(t) \Big|_{t=nT_s} \quad (5)$$

여기서, h_i , τ_i 는 해당 경로의 응답크기와 지연정도를 의미한다. 식(5)는 수신단의 ADC를 통해 T_s 간격으로 표본화되었을 때 수신된 심볼의 n 번째 샘플을 나타낸다.

이러한 다중경로 채널를 통해 OFDM 심볼이 전송될 때 생기는 여러 지연확산에 의해 인접한 두 심볼간의 간섭 (ISI : Inter Symbol Interference)이 발생한다. ISI의 발생은 두 심볼의 정보가 뒤섞여 원할한 복조가 불가능하다. 이와 같은 이유로 OFDM 심볼은 송신 전 최대지연확산보다 긴 보호구간 (Guard-Interval)이 삽입되어 전송된다. 이 구간에는 해당 심볼의 직교성 파괴 방지를 위하여 유효심볼의 마지막 구간의 신호를 복사하여 삽입하고 이를 주기적 프리픽스 (CP : Cyclic Prefix)라고 한다. Fig.2는 ISI의 발생과 CP를 활용한 전송의 모습을 보여준다.



(a)



(b)

Fig.2 (a) ISI 발생 전송 (b) CP를 활용한 전송

Fig.2 (b)의 T_{cp} 는 CP의 길이를 나타내며 이처럼 CP를 활용한 전송의 경우 OFDM 심볼주기는 $T + T_{cp}$ 가 된다. 수신단에서는 ISI의 발생이 T_{cp} 구간 이후로는 일어나지 않는 점을 활용하여 심볼의 뒷부분 T 구간만을 복조에 활용한다.

실제 OFDM 변조시 각 부반송파에 할당될 데이터는 사전에 위상천이 키잉 (PSK : Phase Shift Keying)이나 직교 크기 변조 (QAM : Quadrature Amplitude Modulation)의 과정을 거쳐 부반송파에 할당된다^[9]. 즉, 식(2)의

M_k 는 이러한 변조과정을 거친 복소수 심볼이다. 본 논문에서는 기존의 전송 모델과 제안하는 전송 모델의 비교에 있어 모두 QPSK 변조 방식을 이용한다. Fig.3은 OFDM 전송의 전체 과정을 보여준다.

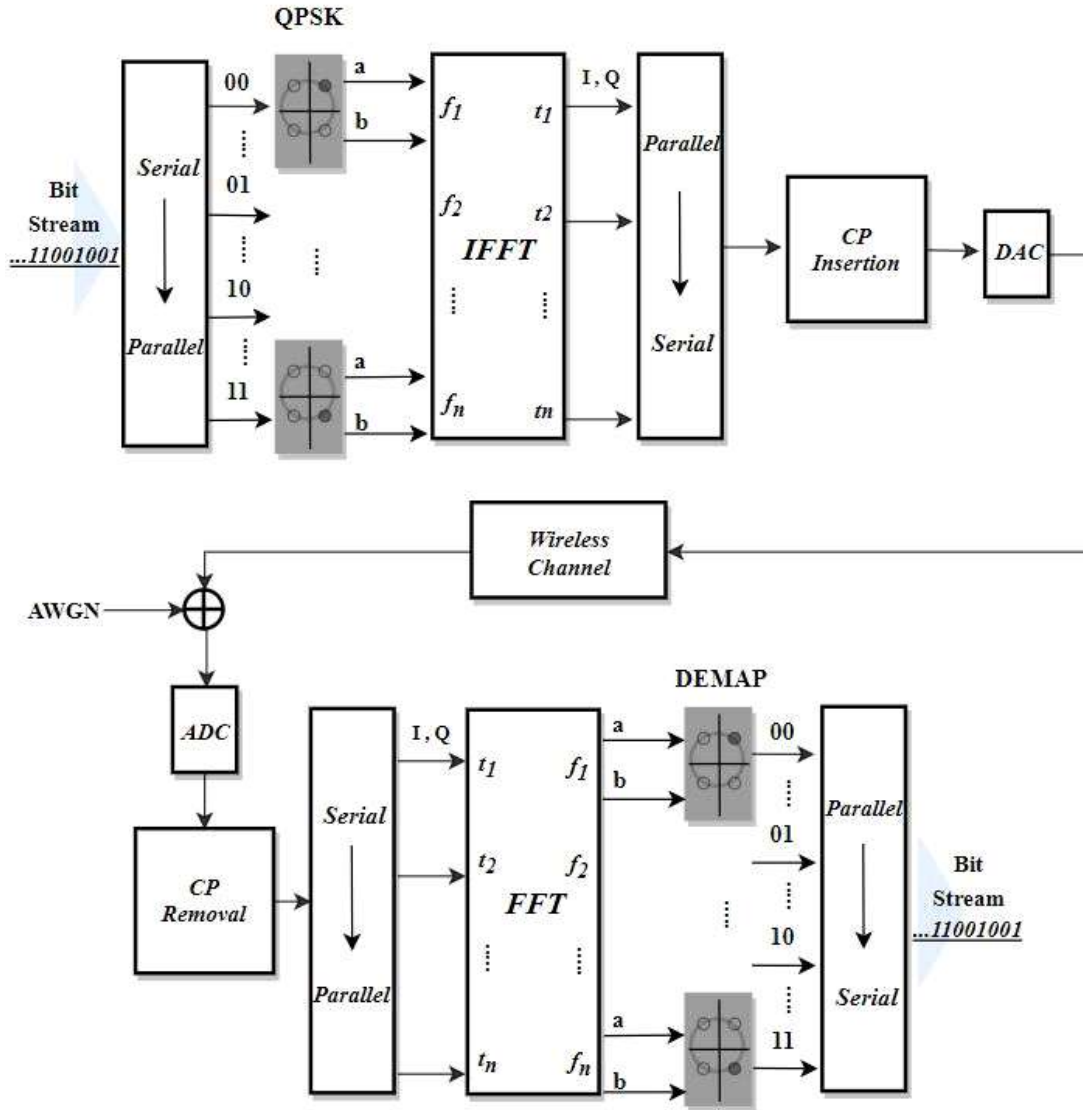


Fig.3 기존 OFDM 전송 블록 흐름도

II-2. 인공신경망 기초 이론

본 논문에서 CP를 예측하기 위해 사용할 인공신경망 모델은 은닉층 (Hidden Layer)이 다수 쌓인 형태이기 때문에 심층 신경망 (Deep Neural Network) 모델이라고 할 수 있다.

Type	Output
<i>Linear score function</i>	$o = Wx$
<i>N-Layer NN</i>	$o = NN(x) = W_l f(W_{l-1} f(\dots W_2 f(W_1 x \dots)))$

Table 1 Output of Single and Multi-Layer NN

Table 1은 단층모델과 다층으로 구성된 심층신경망의 차이를 나타낸다. 이러한 모델은 학습 데이터(x)가 은닉층(h_l)을 거쳐 갈 때마다 모델에 있는 n 개의 뉴런과 가중치 행렬 W 가 곱해진 값들의 합이 비선형함수(f)를 통과하기 때문에 복잡한 구조의 결과(o)도 더욱 효율적으로 예측할 수 있다. Fig.4는 이를 시각적으로 나타낸 것이다. 은닉층의 수가 늘어날수록 비선형 연산의 수도 늘어나게 됨을 확인할 수 있다.




Fig.4 심층 신경망 (Deep Neural Network)

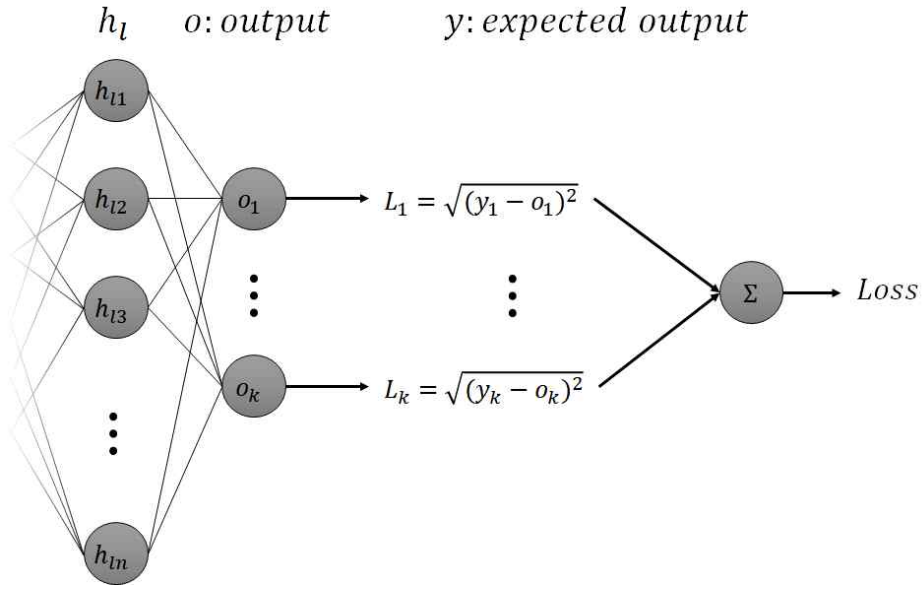


Fig.5 손실함수의 계산 (Mean Square Error)

Fig.5에 나타난 신경망의 학습은 입력된 training data가 심층 신경망을 통해 나온 결과와 output data와의 차이를 계산하여 한 epoch 마다 가중치 W 를 update하는 방식으로 이루어진다. 오차는 가중치 W 에 대한 함수인 손실함수로 정의된다. 각 가중치가 ‘손실함수에 끼치는 영향’이라 표현할 수 있는 gradient를 근거로 update가 이루어지는데, 이는 편미분과 Chain-Rule을 통해 알아낼 수 있다. 이 때 손실함수를 Mean-Square-Error로 계산한다면 식(7)과 같이 표현할 수 있다.

$$\begin{aligned}
 W_{n+1} &= W_n - r \frac{\partial}{\partial W} Loss(W) \quad , (r : Learning Rate) \\
 &= W_n - r \frac{\partial}{\partial W} \frac{1}{2k} \sum_{m=1}^k (y_m - o_m)^2 \quad (7)
 \end{aligned}$$

이 때 모델이 일반화가 되지 못하고 training data의 오류만을 낮추기 위해 지나치게 훈련되는 경우가 있는데 이를 과대적합 (Over-fitting) 문제라고 한다. 과대적합이 발생하게 되면 훈련에 사용하지 않은 새로운 데이터를 입력할 시에, 적절한 예측 값을 내놓지 못하는 결과를 가져온다^[10]. 이를 해결하기 위한 방법으로는 과대적합을 일으키는 특징의 영향을 줄이기 위해 손실함수에 정규화 식 (Regularization Term)을 붙여주거나 전체 가중치를 훈련에 참여시키는 것이 아닌 일부만을 사용하는 ‘Drop-out’ 등이 있다^[11]. 본 논문에서는 일반화를 위해 drop-out의 방법을 이용하였다.

III. 인공신경망을 이용한 CP 대체 OFDM 시스템 설계

III-1. 시스템 설계 구상

앞서 기술된바와 같이 OFDM방식에서 심볼을 전송할 때 ISI의 발생을 막기 위하여 CP를 활용하여 전송하였다. 이는 ISI 방지와 신호의 직교성 유지에는 효과적이거나 심볼 주기의 증가에 따른 데이터 전송의 비효율성 또한 발생하게 된다. 본 논문에서는 이러한 비효율성을 개선하기 위하여 ANN (Artificial Neural Networks)을 이용하여 CP를 삽입하지 않고도 위와 같은 문제를 해결할 수 있는 OFDM 시스템을 설계하고자 한다. Fig.5는 이에 대한 간략한 구상도를 보여준다. 송신부에서 신호를 송신 시 CP를 삽입하지 않고 송신하고 ANN은 수신부에서 심볼의 ISI 발생 구간을 정상신호로 예측하는데 활용한다.

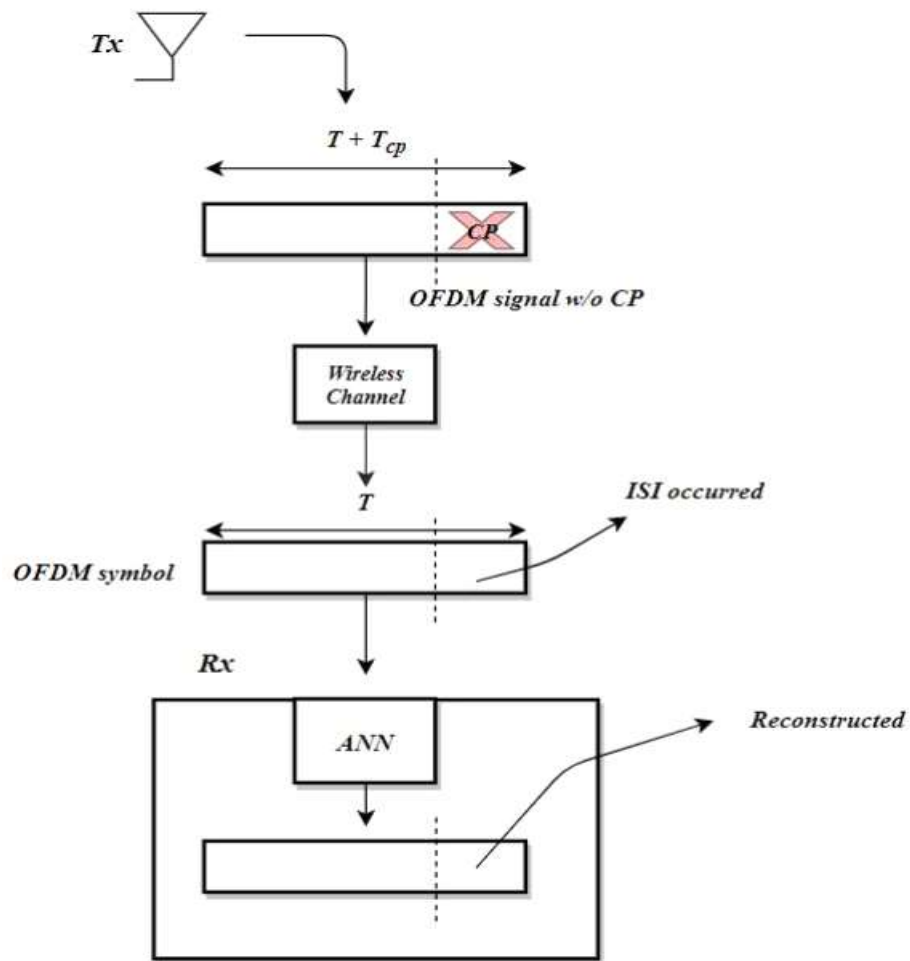




Fig.6 시스템 설계 구상도

III-2. 학습 데이터 생성

수신부에 적용될 인공신경망 모델 생성에 있어 OFDM 신호를 학습에 활용할 수 있는 형태로 만들어야 한다. 본 논문에서는 인접한 두 OFDM 심볼 간의 관계를 통해 입출력 데이터를 생성한다. 단, 새롭게 구현할 시스템은 채널추정이 용이하고, 인접한 두 심볼은 같은 무선채널을 통과한다고 가정한다.




(a)



(b)

본 논문에서 제안하는 시스템은 CP가 삽입되지 않은 신호를 송신한다. 이때, 송신 신호는 연속한 두 심볼의 정보가 ISI로 인해 뒤섞인 구간과 ISI가 발생하지 않아 각 심볼의 정보만 존재하는 두 구간으로 나뉜다. 두 구간 중 ISI 미 발생 구간과 채널의 정보가 입력 데이터로 활용된다. 출력 데이터는 ISI 발생 구간을 정상신호로 대체하여 인접한 두 심볼 중 후행 심볼의 정보만 존재하는 구간으로 만들어 활용한다. Fig.7의 (a),(b)는 이러한 입·출력 데이터의 생성을, (c)는 적용된 인공신경망의 학습을 가시적으로 나타낸 그림이다.



(c)

Fig.7 (a)입력 데이터 생성 (b)출력 데이터 생성 (c)적용 신경망 블록도

본 논문에서는 모델 생성을 위해 python 기반의 Keras library를 활용하여 복소수의 형태인 모든 입·출력 신호들을 실수와 허수 형태로 분리하여 생성하고 처리한다.

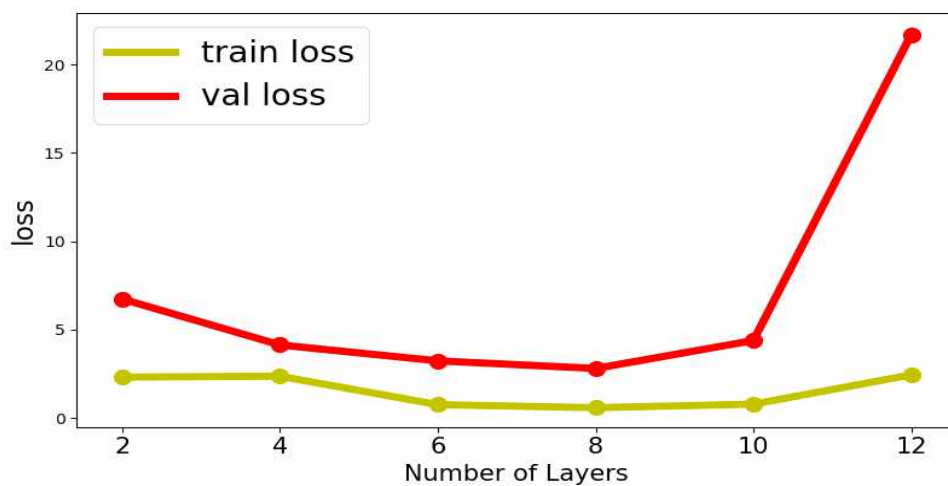
III-3. 선형회귀 모델 생성 및 최적화

본 논문에서는 Jupyter Notebook 개발 환경에서 모델 생성을 진행한다. Keras 라이브러리를 통한 생성의 기본적인 파라미터는 Table 2와 같다.

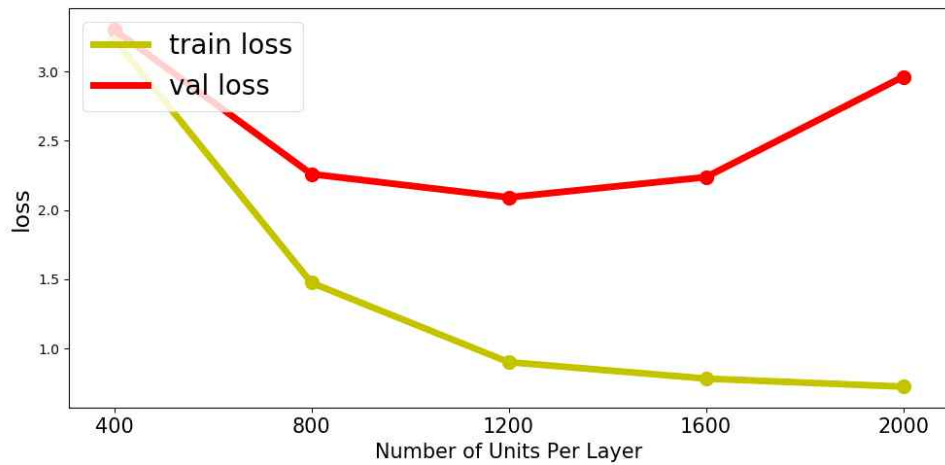
Parameter	Property
Activation Function	Hidden Layer : ReLU Output Layer : Linear
Loss Function	MSE (Mean-Square-Error)
Optimizer	Adamax
Batch size	640
Sample size	Train set : 600000 Cross Validation set : 100000 Test set : 100000
Epoch	1000
Weight Initializing	Normal Gaussian Distribution

Table 2 모델 생성 기본 파라미터

Table 2와 동일한 조건하에 은닉층의 수와 각 은닉층의 유닛 수를 조정하며 과대적합과 과소적합 사이의 최적의 조건을 찾아 모델을 생성한다. Fig.8은 각 은닉층, 유닛 수에 따른 과소적합 또는 과대적합의 결과를 보여준다.



(a)



(b)

Fig.8 (a)은닉층 수에 따른 손실 변화 추이 (b)유닛 수에 따른 손실 변화 추이

Layers	2	4	6	8	10	12
tr_loss	2.32051	2.36808	0.75225	0.58329	0.7846	2.4467
cv_loss	6.73336	4.13165	3.23882	2.80104	4.387	21.6833

(a)

Units	400	800	1200	1600	2000
tr_loss	3.2352	1.4753	0.902	0.7833	0.7251
cv_loss	3.3025	2.2598	2.0917	2.2377	2.9626

(b)

Table 3 (a)은닉층 수에 따른 손실 (b)유닛 수에 따른 손실

위 두 실험의 손실값을 토대로 8개의 은닉층과 1200개의 유닛을 최적의 파라미터로 선정하여 모델을 생성하였다. Fig.9은 해당 모델의 Epoch에 따른 손실의 변화이다.

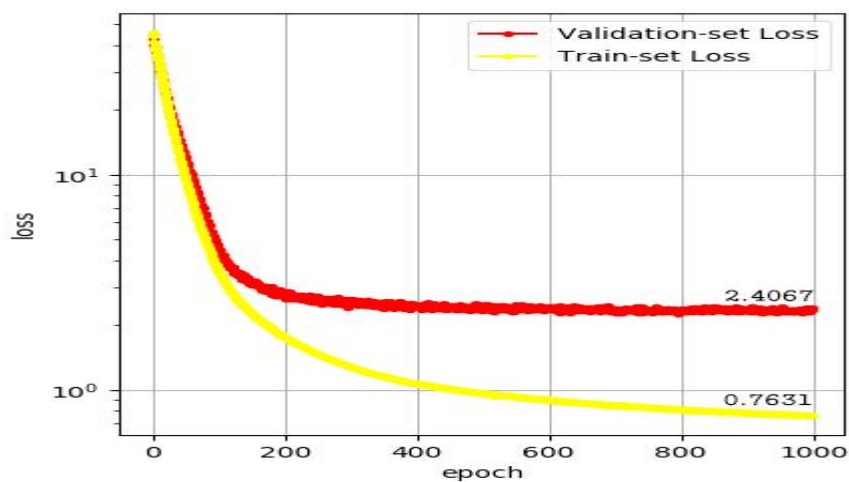


Fig.9 Epoch에 따른 최종 모델 손실

III-4. 인공신경망 적용 시스템

다음 Fig.10는 III-3에서 최적화한 인공신경망을 기존 수신부에 적용한 블록도이다. 인접한 두 심볼 각각의 ISI 미발생 구간을 인공신경망의 입력으로 활용한다. 이 인공신경망의 출력으로 후행 심볼의 ISI 발생 구간을 대체하여 심볼을 재구성한 뒤 기존과 동일한 복조과정이 이루어진다.

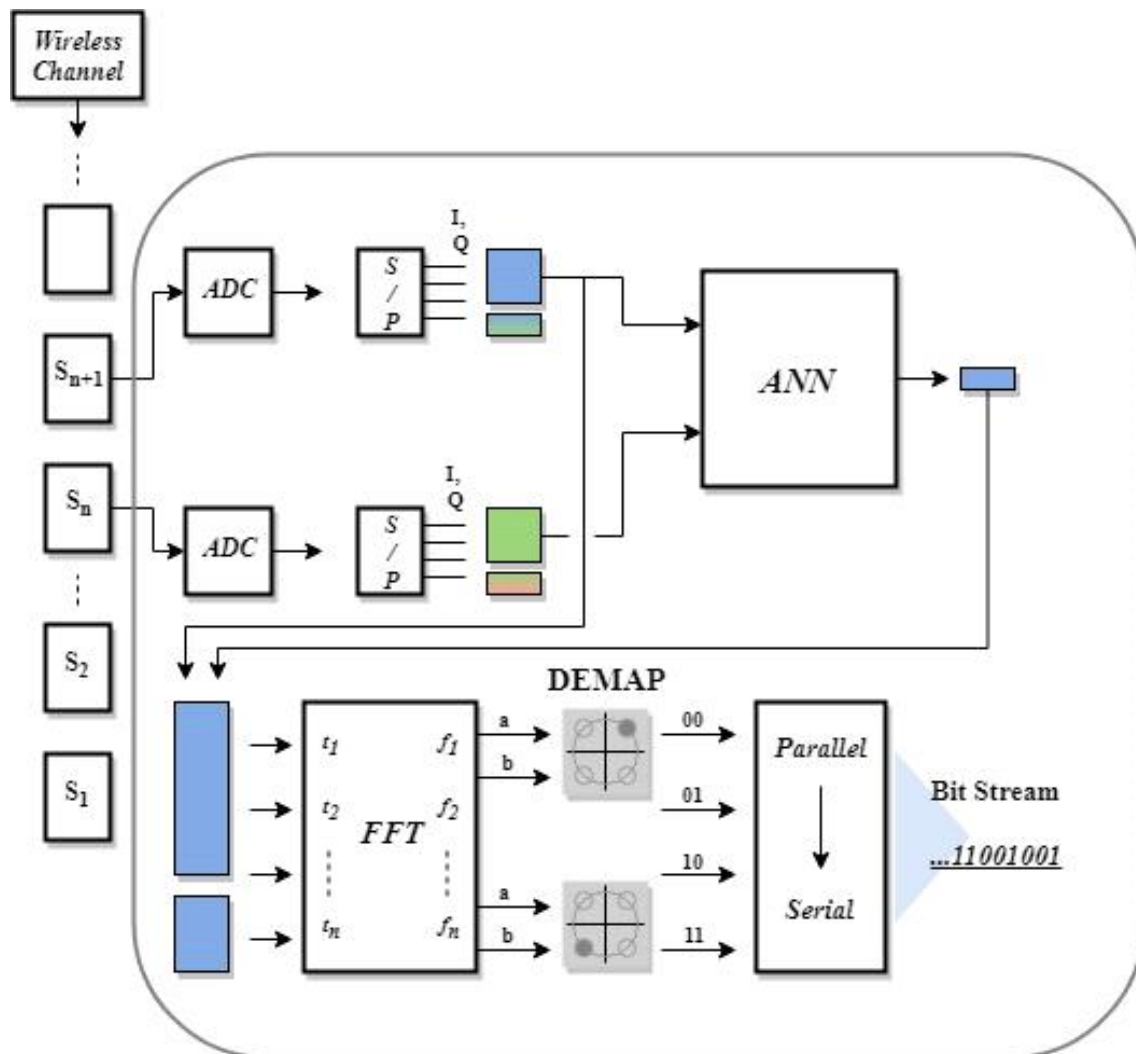


Fig.10 인공신경망 적용 수신부 블록도

IV. 성능평가 및 분석

IV-1. 실험 환경

앞서 설계한 모델의 성능을 평가하기 위해 MATLAB을 이용하여 시스템의 송·수신부를 구현하였다. 구현에 있어 사용된 각 송·수신부의 파라미터 값은 Table 4에 명시된 바와 같다. Table 4은 802.11a 무선 LAN 표준의 파라미터와 본 논문에서 제시하는 인공 신경망 적용 시스템의 파라미터를 비교한 것이다.

Parameter	무선 LAN 표준 (802.11a)	인공신경망 적용 시스템
반송파 수	52	52
FFT 크기	64	64
심볼 주기	80	64
보호구간 길이	16	0
변조방식	BPSK QAM (4 ~ 64)	QPSK

Table 4 송·수신부 구현 파라미터 비교

본 실험에서의 심볼 전송 시에 고려되는 전송 환경의 파라미터는 다중경로의 개수, 채널 경로 응답의 전력 분포, 백색 가우시안 잡음의 크기를 고려하여 반영하였다. 이는 일반적인 전송 환경과 정확히 일치하지는 않는다. Table 5는 각 파라미터의 값을 보여준다.

Parameter	Property
Power Delay Profile	Exponential Decay
Number of Muti-path	4, 8
SNR Range	10 dB ~ 35 dB

Table 5 전송 환경 파라미터

IV-2. 시스템의 수신 성상도

Fig.11은 앞선 Table 4의 환경에서 CP를 사용하지 않는 모델과 ANN을 적용한 모델의 성능을 비교하기 위한 수신 성상도 그림이다. (a), (b)는 각각 Table 5와 같은 채널환경을 따른다.

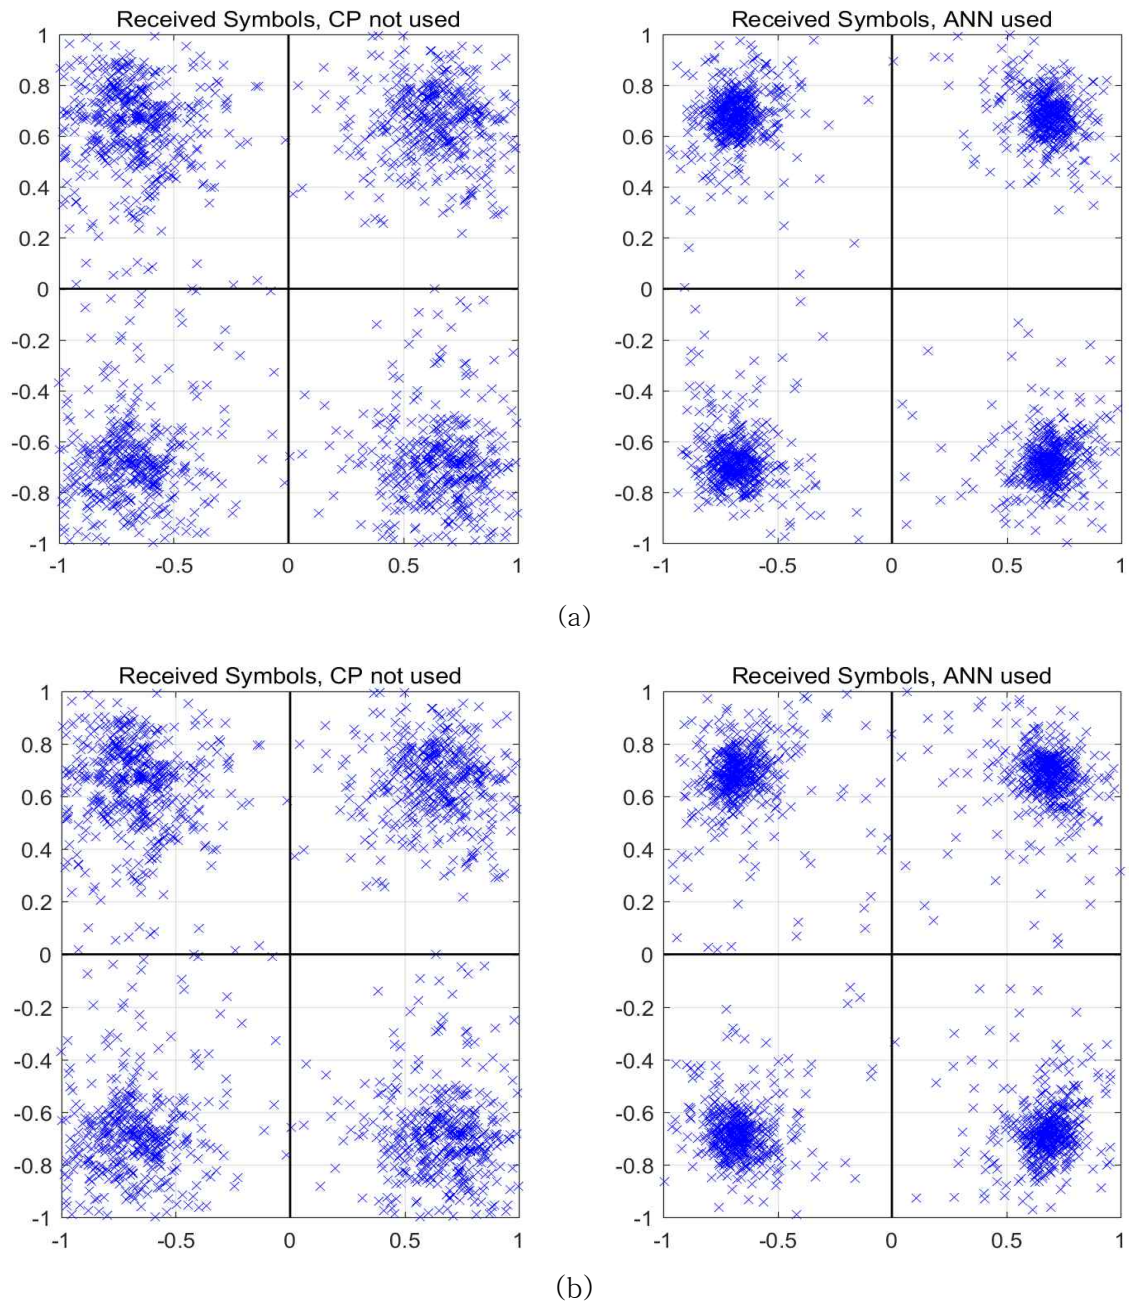


Fig.11 (a) 4채널 환경 성상도 비교 (b) 8채널 환경 성상도 비교

두 경우 모두 ANN을 적용한 시스템에서 보다 정확한 분포를 보인다. 특히, 다중경로의 수가 적을수록 성능이 향상되는 정도가 커진다.

IV-3. 시스템의 BER 곡선

Table 6은 앞선 Table 4의 환경에서 CP를 사용하지 않는 모델, ANN을 적용한 모델, 그리고 CP를 사용하는 모델의 SNR (Signal Noise Ratio)별 성능을 비교하기 위한 심볼 오류율 (Symbol Error Rate) 값을 정리한 표이다. 해당 실험의 노이즈의 크기는 Table 5의 SNR 범위를 따른다. Fig.12는 각 환경에서의 CP를 사용하지 않는 모델과 ANN을 적용한 모델의 SER 값을 비교한 그래프이다.

SNR (dB)	SER		
	RX signal (CP used)	RX signal (ANN used)	RX signal (CP not used)
10	7.28E-04	5.05E-02	4.47E-02
15	2.23E-04	2.54E-02	4.40E-02
20	7.08E-05	1.51E-02	4.37E-02
25	2.23E-05	1.16E-02	4.29E-02
30	5.77E-06	1.04E-02	4.24E-02
35	2.69E-06	1.01E-02	4.20E-02

Table 6 신호 대비 잡음 비율별 세 모델의 각 심볼 오류율

Table 6의 각 항목별 오류율을 살펴보면 기존 OFDM 신호는 CP 사용 여부와 관계없이 노이즈의 크기에 큰 영향을 받지 않는다. 반면 ANN을 적용한 모델의 경우 잡음의 크기에 영향을 크게 받는 것을 알 수 있다. 10 dB의 SNR 환경에서는 ANN을 적용한 모델이 기존 CP를 사용하지 않는 모델과 비교하여 88.5%의 성능을 보인다. 하지만 15 dB의 SNR 환경에서 175.2%, 35 dB의 SNR 환경에서 435.6% 등 15 dB 이상의 환경에서는 보다 개선된 성능을 보인다.

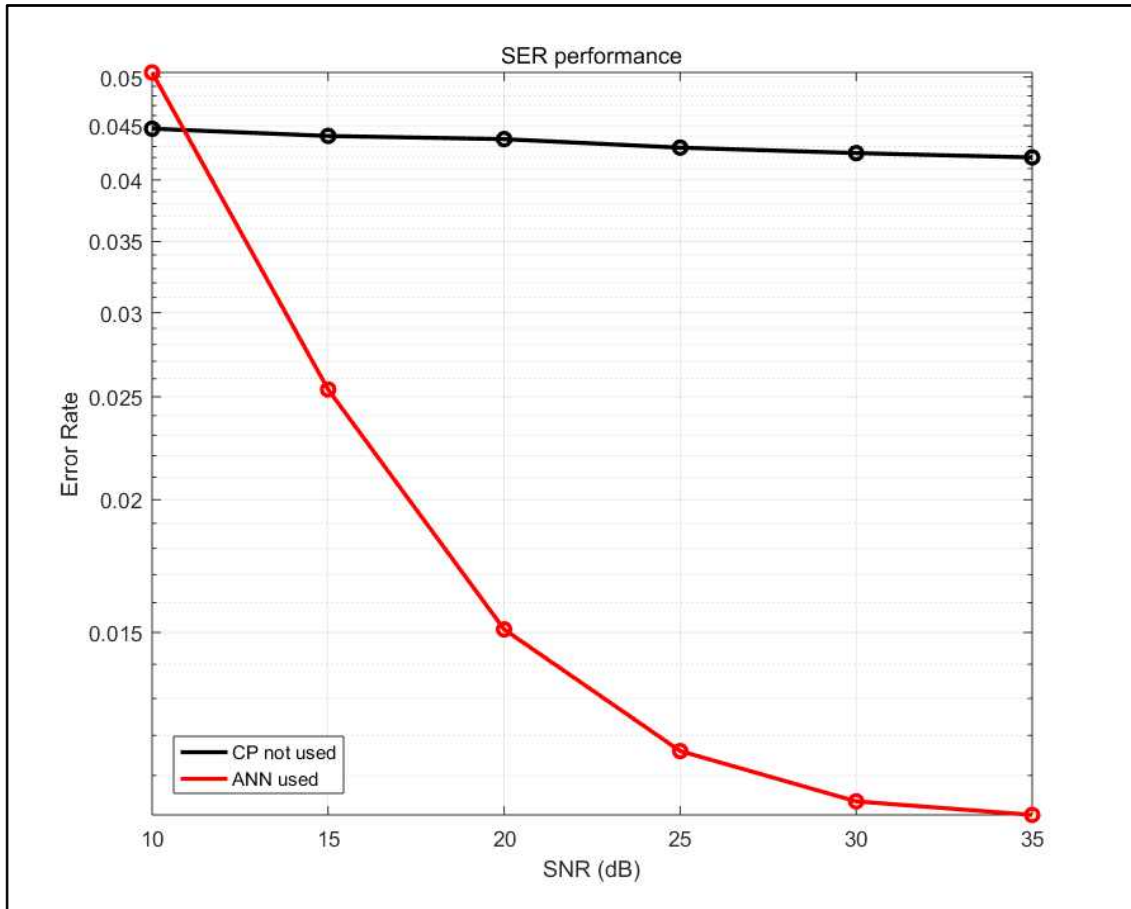


Fig.12 신호 대비 잡음 비율에 따른 두 모델의 심볼 오류율 비교

기존의 CP를 사용하는 모델의 성능과 비교하였을 때 ANN을 적용한 모델의 성능은 여전히 좋지 않다. 그러나 25%의 전송율 개선을 고려하면 본 논문에서 진행한 ANN을 통한 OFDM 통신 방식 실험은 잡음의 크기가 다소 작은 통신 환경에서 CP를 쓰지 않고도 더 나은 성능과 전송율로 통신이 가능함을 알 수 있다.

V. 결 론

본 논문에서는 다양한 유, 무선 통신에서 활용되는 OFDM 시스템의 효율성 개선을 목적으로 인공신경망을 활용하였다. 기존 OFDM 시스템은 신호 전송 시 CP를 이용하여 직교성을 확보하여 오류율을 줄이는 방법을 사용하였는데, 본 논문에서는 인공신경망을 활용함으로써 CP를 사용하지 않는 새로운 시스템을 제안하였다. 적절한 인공신경망 모델을 얻기 위해 MatLab을 통해 훈련 및 검증 데이터를 생성하였고, 해당 데이터를 머신러닝에 이용하여 모델을 최적화 시켰다. 일반적인 통신환경과 유사한 실험 상황을 가정 후 모델을 적용한 시스템의 성능을 평가하였다.

본 논문에서 제안한 시스템의 성능은 동일한 조건 하 CP를 사용하지 않는 방식과 동등한 전송율을 보이면서도 CP를 사용하지 않는 방식 대비 170% ~ 430% 가량의 심볼 오류율 개선을 보여주었다. 그러나 기존 OFDM 방식에 비하여 잡음의 크기에 취약하며 CP를 사용하는 방식의 성능에는 못 미치는 결과를 확인할 수 있었다. 따라서 이는 OFDM 시스템의 전체 적인 개선보단 부분적 개선이 이루어졌다고 볼 수 있다. 본 논문에서 진행한 실험을 통하여 잡음의 크기가 다소 작은 통신 환경에서 인공 신경망과 머신러닝의 활용을 통해 CP를 쓰지 않고도 보다 낮은 오류율과 높은 전송율로 통신이 가능함을 알 수 있었다.

참고문헌

- [1] ETSI EN 300 401, “Radio Broadcasting Systems: Digital Audio Broadcasting(DAB) to Mobile, Portable and Fixed Receivers,” Sep. 2000.
- [2] ETSI EN 300 799, “Digital Video Broadcasting(DVB); Framing, Structure, Channel Coding, and Modulation for Digital Terrestrial Television,” June 1999
- [3] IEEE 802.11a, “High Speed Physical Layer in the 5GHz Band“ , 1999
- [4] IEEE 802.16, ‘IEEE Standard for Air interface for Broadband Wireless Access Systems’, 2012
- [5] Anju, Ahlawat, Amit, “A Review on Orthogonal Frequency Division Multiplexing (OFDM)”, *International Journal of Recent Research Aspects*, Vol. 3 Issue 2, pp.112-115, June 2016.
- [6] H. Ye, G. Li, and B. Juang, “Power of deep learning for channel estimation and signal detection in OFDM systems,” *IEEE Trans. Wireless Commun. Lett.*, Vol. 7, no. 1, pp.114-117, Feb. 2018.
- [7] Qing-Ming Yi, Min Shi, “A New Algorithm of Frequency Offset Estimation”, 2007 International Conference on Machine Learning and Cybernetics, 2:813-817 Aug, 2007
- [8] R. V. Nee, R. Prasad, “OFDM for Wireless Multimedia Communications,” Boston, MA: Artech House, Dec. 1999.
- [9] 조용수, 장경희, ‘Beyond IMT-2000 시스템을 위한 OFDM 무선 전송 기술’, *전자통신동향분석* 17. 1, pp.32-47, 2002
- [10] Nitish Srivastava, Geoffrey Hinton, “Dropout: A Simple Way to Prevent Neural Networks from Overfitting,” *Journal of Machine Learning Research* 15,

pp.1929–1958, June 2014

[11] Tikhonov, A.N., “Solution of Incorrectly Formulated Problems and the Regularization Method,” *Soviet Mathematics Doklady*, pp. 1035–1038, Apr. 1963